Documentação 6: Rastreamento de dados pelo CPF

Thiago Fernandes Canonici

1. JUSTIFICATIVA:

Esta entrega foi um aprimoramento da entrega 4 (parcelas atrasadas e dias de atraso) e correção da entrega 5 (validação de CPF's). Primeiro verificou-se a veracidade dos CPF's para a decisão de alocação de recursos para a previsão de comportamento das pessoas físicas. CPF's falsos foram descartados, pois se mostraram ineficazes, fugindo de uma entrega de valor.

2. OBJETIVO:

Objetivou-se aplicar um sistema de filtragem de CPF's válidos, rastreamento das faturas, parcelas atrasadas, dias atrasados e relatório de erros caso houver, usando os mesmos CPF's. Esses dados são importantes para a previsão de comportamento das pessoas físicas. O levantamento de dados de CPF's inválidos é ineficaz.

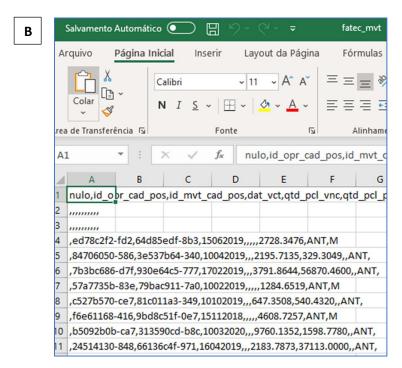
3. MATERIAL E MÉTODO:

As ferramentas utilizadas foram o idle do python para a programação usando essa linguagem, o *jupyter notebook*, o Libre Office Calc, o Excel, o bloco de notas extensão "txt" e as tabelas fornecidas pelo SPC.

3.1. Libre Office Calc e Excel:

Esta ferramenta foi utilizada para o preparo dos dados para sua manipulação no *jupyter notebook*. Como as tabelas estavam em extensão ".csv" o "Calc" foi o melhor software para manipular diretamente as colunas das tabelas para sua formatação e preparo para que sua análise fosse possível (Fig.1).

Figura 1: Página inicial da abertura das tabelas em "Calc", **A**, e Excel, **B**. Nota-se em **A** que as colunas estão separadas (guia "Campos"); Em **B** as colunas estão todas juntas como mostrado na área de trabalho.



3.2. BLOCO DE NOTAS:

O bloco de notas foi usado para salvas as colunas de datas das tabelas para a aplicação de códigos ¹ criados de formatação de datas e adição de zero a valores nulos. O código "nulo" foi adaptado para inserir zero no início das datas com 7 algarismos para, em seguida, rodar o código "data". Essa ordem é importante para a separação de dia, mês e ano corretamente, pois a posição dois da data "9122019" é o número 2, resultando em "91/22..."; em oposição a "09122019", resultando em "09/12...". Substituiu-se os valores resultantes nas colunas das tabelas do SPC (foram feitos backups das tabelas originais caso houvesse algum arquivo corrompido ou erro humano).

Os arquivos foram salvos e abertos no Excel para finalizar a formatação por algumas incompatibilidades entre o "Calc" e o Excel, para serem manipulados no *jupyter* notebook.

3.3. JUPYTER NOTEBOOK:

O jupyter notebook é uma ferramenta de análise de dados, em que sua instalação no computador é obrigatória e seu acesso é feio por linha de comando digitando "jupyter notebook <ENTER>". Uma página da web em seu navegador principal abrirá. Todas as bibliotecas a serem utilizadas devem estar instaladas no computador; a biblioteca "pandas" e "matplotlib.pyplot" foram as requisitadas.

¹ Estes códigos foram documentados na *Sprint* 1. Sua descrição seria prolixa.

4. RESULTADO E DISCUSSÃO:

Nesta entrega final do projeto, os dados passaram por vários testes e filtros, identificando CPF's que passaram na lógica aplicada pelo Ministério da Fazenda.

Serão exibidos nas telas do aplicativo os gráficos, as tabelas de valor e tabelas mostrando os erros de 13 CPF's ou o que estiver documentado nas tabelas do SPC. No caso da tabela de endereço, só há 12 CPF's registrados.

4.1. PREPARO DOS CPF'S PARA A VALIDAÇÃO:

Os CPF's contêm exatos 11 algarismos. Ao inserir um valor que comece com zero no Excel ou Calc, o software deleta esse zero inicial. Pressupôs-se² que os CPF's de dez algarismos começassem por zero.

O código "nulo" foi adaptado para a inserção de zero em CPF's com 10 algarismos. O programa pega cada número, passa por um código condicional avaliando o comprimento e insere o zero na primeira posição caso o comprimento seja igual a dez, retornando ao final todos os CPF's no tratamento inicial (Fig. 2). Nesta etapa não se tem os valores válidos dos CPF's.

Figura 2: Função em python para a inserção de zero na primeira posição nos CPF's com 10 algarismos.

```
In [334]: def cpf(a):
    a = str(a)
    a = list(a)

if len(a) == 10:
    a.insert(0, '0')

a = ''.join(a)
    return a
```

² Erro possível: Necessita-se da confirmação do SPC para saber se a pressuposição está correta.

4.2. VALIDAÇÃO DE CPF'S:

Elaborou-se um novo código baseado em uma outra referência bibliográfica que utiliza o raciocínio lógico do Ministério da Fazenda (ALGORITMO PARA VALIDAR CPF, 2015?), pois a da quinta entrega reprovou nos testes. O grupo controle dos testes embora pequeno, cinco CPF's, surtiu efeito na validação do código; ele está no GitHub na pasta "Semana 6/Análise backEnd" arquivo "validade cpf.py" para testes futuros.

Os testes foram conduzidos escrevendo o número do CPF em aspas simples ou duplas dentro da função "validade()" os resultados possíveis foram 'válido' ou 'inválido'. Alterou-se a ordem dos números dos CPF's mantendo os 11 algarismos e o resultado foi 'inválido'. O algoritmo passou nos cinco testes.

O uso de aspas é obrigatório para que o interpretador do python entenda o valor digitado como número decimal, ou ele entenderá como número octal caso o CPF comece com zero.

O código consiste na separação do número de CPF do dígito. Ex.: XXX.XXX.XXX, número do CPF: XXX.XXX.XXX, dígito -XX. Faz-se algumas multiplicações com cada algarismo e aplica-se uma somatória, multiplica-se por dez e divide-se por 11. Compara-se o resto da divisão com o primeiro dígito do CPF; pega-se uma nova sequência do CPF, agora incluindo o primeiro dígito, e compara-se o resto da divisão com o último dígito. Se ambos os restos forem iguais aos respectivos dígitos, então o CPF é verdadeiro (ALGORITMO PARA VALIDAR CPF, 2015?). Esta lógica ³ teve de ser adaptada, porque os primeiros testes deram errado, CPF's com todos os números repetidos podem dar válido mesmo não o sendo, exemplo: 111.111.111-11 seria válido, além de outras complicações (Fig. 3).

De 3012 linhas na coluna "cpf" do arquivo "fatec_pessoa_fisica", 13 CPF's foram retornados com a aplicação da função da figura 3 e eliminação dos campos nulos (Tab. 1). Foram esses 13 CPF's (tabela 1) usados para o rastreamento das parcelas, dias do pagamento e faturas. O restante, 2989, foi exibido como erro, e não como indicador.

³ O código está disponível no arquivo validade_cpf para o teste de mesa para o melhor entendimento de seu funcionamento.

Como os testes foram poucos, pegou-se cada CPF resultante e pesquisou-se no website da Receita Federal. A verificação da resposta do website foi feita com um CPF inválido digitado de forma aleatória (Fig. 4A). A resposta foi "CPF incorreto. (...)" (Fig. 4B). Sabendo do tipo de resposta da interface gráfica, pesquisou-se os CPF's achados na tabela do SPC. A figura 4C exibe o resultado desta pesquisa com a resposta "Data de nascimento (...) está divergente (...)", sem apontar erro ao CPF.

Figura 3: Código de validação usado no jupyter notebook (A a D).

```
A def valido(g):
    b = str(g)
    a = 0
    d = 0
```

```
if len(b) == 11:
В
       c = list(b)
       if b[0]:
           c[0] = str(int(b[0])*10)
       if b[1]:
           c[1] = str(int(b[1])*9)
       if b[2]:
           c[2] = str(int(b[2])*8)
       if b[3]:
           c[3] = str(int(b[3])*7)
       if b[4]:
           c[4] = str(int(b[4])*6)
       if b[5]:
           c[5] = str(int(b[5])*5)
       if b[6]:
           c[6] = str(int(b[6])*4)
       if b[7]:
           c[7] = str(int(b[7])*3)
       if b[8]:
           c[8] = str(int(b[8])*2)
       cont = 0
       for j in range(9):
           cont += int(c[j])
```

```
C
   if str((cont*10)%11) == b[-2]:
       d += 1
   if b[0]:
       c[0] = str(int(b[0])*11)
   if b[1]:
       c[1] = str(int(b[1])*10)
   if b[2]:
       c[2] = str(int(b[2])*9)
   if b[3]:
       c[3] = str(int(b[3])*8)
   if b[4]:
       c[4] = str(int(b[4])*7)
   if b[5]:
       c[5] = str(int(b[5])*6)
   if b[6]:
       c[6] = str(int(b[6])*5)
   if b[7]:
       c[7] = str(int(b[7])*4)
   if b[8]:
       c[8] = str(int(b[8])*3)
   if b[9]:
       c[9] = str(int(b[9])*2)
   cont = 0
   for j in range(10):
       cont += int(c[j])
```

```
e = str((cont*10)%11)
if e[-1] == b[-1]:
    d += 1

for i in range(len(b)-1):
    if b[i] == b[i+1]:
        a += 1

if d == 2 and a != 10:
    return g
```

Tabela 1: Após a aplicação do algoritmo de validação de CPF's, obtiveram-se 13 linhas diferentes de nulo.

Data columns (total 2 columns):

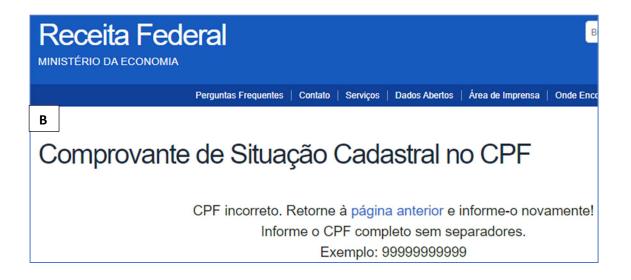
Column Non-Null Count Dtype

0 nulo 0 non-null object
1 cpf 13 non-null object
dtypes: object(2)
memory usage: 312.0+ bytes

	nulo	cpf
66	NaN	64122018315
258	NaN	05227401381
260	NaN	06090237051
1252	NaN	05309680888
1515	NaN	53829829299
1805	NaN	11435403525
1811	NaN	09639103101
1888	NaN	24048813021
1893	NaN	28537130320
2044	NaN	38553034011
2316	NaN	12731112573
2854	NaN	18106900800
2925	NaN	01367130760

Figura 4: Teste de verificação da veracidade dos CPF's descobertos (**A-C**). **A:** CPF digitado aleatoriamente para descobrir qual é a resposta que o website dá. **B:** Resposta do website, note que a resposta é "CPF incorreto". **C:** Resposta do website com um CPF resgatado com o algoritmo de validação de CPF's. Note que a resposta foi que a data de nascimento estava incorreta.







4.3. CPF'S INVÁLIDOS:

Há 2.989 campos inválidos de CPF. A tabela 2 exibe 10 deles. Note que existem CPF's com 11 algarismos inválidos. Eles foram excluídos pela validação de CPF's e, portanto, considerados erros.

Tabela 2: Dez CPF's inválidos resgatados como erro. O total de erros verificado são 2989 campos da coluna "cpf". Note a ocorrência de CPF's com 11 algarismos que também são considerados inválidos.

	nulo	cpf
2	NaN	37311167211
3	NaN	34115266395
4	NaN	35622655491
5	NaN	33222324480
6	NaN	1505546115
7	NaN	33934682013
8	NaN	1230119467
9	NaN	42785953989
10	NaN	35515466259
11	NaN	33160354240

4.4. RESGATE DOS ENDEREÇOS DOS CPF'S VÁLIDOS:

Utilizaram-se os CPF's válidos como chave primária para o resgate das linhas do arquivo "fatec_endereco_pessoa_fisica". Dos 13 CPF's 12 estão registrados com o 01367130760 ausente. Para a identificação dos estados na coluna "estado de origem do cpf", verificou-se o último algarismo do CPF antes do dígito. Exemplo: XXX.XXX.XX(NUM)-XX (CPF-Dígito), em NUM lê-se o algarismo de 0 a 9 que dirá qual é o estado. Desses 12, um não se deslocou da região de origem do CPF. Note que alguns algarismos de estado do CPF pertencem a mais de um estado (tabela 3).

Tabela 3: Tabela de endereço. As Colunas "id_pessoa_fisica", "cidade atual" e "estado atual" são dados do SPC; A coluna "estado de origem do cpf" foi filtrada usando os CPF's válidos. Note que há registro de 12 CPF's com o 01367130760 faltando e que o rastreamento do estado de origem do CPF pode referir-se a mais de uma localidade.

estado de origem do cpf	estado atual	cidade atual	id_pessoa_fisica
Bahia-Sergipe	CEARA	AQUIRAZ	687332675
Rio Grande do Sul	SAOPAULO	GUARULHOS	123419344
Pará-Amazonas-Acre-Amapá-Rondônia-Roraima	PARANA	CURITIBA	73248792
Ceará-Maranhão-Piauí	SAOPAULO	ELIASFAUSTO	78942456
São Paulo	CEARA	FORTALEZA	339197808
Rio Grande do Sul	SAOPAULO	SAOPAULO	54871997
Rio Grande do Sul	RIODEJANEIRO	ANGRADOSREIS	662924296
Bahia-Sergipe	PARA	ANANINDEUA	38399368
São Paulo	SAOPAULO	ASSIS	378644008
Ceará-Maranhão-Piauí	SAOPAULO	ARACATUBA	283458923
Ceará-Maranhão-Piauí	BAHIA	SIMOESFILHO	334268000
${\bf Distrito\ Federal-Goiás-Mato\ Grosso-Mato\ Grosso}$	MINASGERAIS	IJACI	25177053

4.5. VERIFICAÇÃO DAS PARCELAS ATRASADAS E DIAS ATRASADOS:

Dos 13 CPF's o cpf 11435403525 não tinha nenhum valor no arquivo "fatec_pgt" que fala sobre o período de pagamento das parcelas. As colunas "qtd_pcl_vnc" e "qtd_pcl_pgr" do mesmo arquivo de todos os CPF's devem ser revistas, pois a maioria estão inteiras nulas.

Para saber os dias atrasados, pegou-se a data de pagamento e subtraiu-se a data de vencimento e sobrescreveu-se na coluna "nulo". Valores menores ou iguais a zero são pagamentos feitos no prazo; maiores que zero são pagamentos atrasados. Na tabela 4A, observa-se o atraso de um pagamento em 29 dias pago em 11/12/2019 do cpf 05309680888. Na tabela 3B, mostra-se que no dia 12/12/2019 não havia parcelas atrasas, o que é válido se compararmos com a tabela 3A que diz que após a data 11/12/2019 não há atrasos. Com exceção da data 12/12/2019 todos os outros campos das colunas "qtd_pcl_vnc" e "qtd_pcl_pgr" estão nulos, o que configura um erro (tabela 4B).

Tabela 4: dados de dias atrasados (**A**) e dados das parcelas a vencer e a pagar (**B**) do 05309680888. **A:** Na coluna "nulo" estão os dias de pagamento em relação aos de vencimento (menor ou igual a zero, pagamento no prazo; maiores que zero, pagamento atrasado). Há um pagamento atrasado efetuado na data "11/12/2019"; **B:** repare que na data "12122019", na coluna "dat_vct", não existem parcelas em atraso (63 - 63 = 0). Se correlacionarmos as duas tabelas, não haverá discordância entre elas nos campos não nulos (63; 63) - **B** - e a data de atraso "2019-12-11" - **A**.

Α	nulo	id_opr_cad_pos	id_mvt_cad_pos	id_pgt_cad_pos	dat_pgt	dat_vct_tfm
-12	3 days	17317f69-f32	fbdbb90b-3b7	dcd9cf62-b76	2019-05-09	2019-09-09
-3	2 days	17317f69-f32	db9358de-89f	2bff3301-c2b	2019-09-10	2019-10-12
2	9 days	17317f69-f32	638c671d-8e3	73cdcf28-8fa	2019-12-11	2019-11-12

В	id_opr_cad_pos	id_mvt_cad_pos	dat_vct	qtd_pcl_vnc	qtd_pcl_pgr
	17317f69-f32	5f33df5d-010	12122019	63	63
	17317f69-f32	fbdbb90b-3b7	9092019	NaN	NaN
	17317f69-f32	638c671d-8e3	12112019	NaN	NaN
	17317f69-f32	db9358de-89f	12102019	NaN	NaN

Na avaliação do cpf 38553034011, não se tem a data das parcelas atrasadas no campo identificado como "NaN", o que é um erro, porque não é possível cruzar as informações de dias atrasados com parcelas atrasadas (tabela 5).

Tabela 5: Erro na coluna "dat_vct" no campo "NaN" do 38553034011. Não é possível correlacionar essa informação com os dias atrasados para a validação. Além de haver valores nulos nas colunas "qtd_pcl_vnc" e "qtd_pcl_pgr".

dat_vct	qtd_pcl_vnc	qtd_pcl_pgr
25062019	NaN	NaN
25012019	NaN	NaN
25122018	NaN	NaN
25112018	NaN	NaN
25082019	NaN	NaN
25072019	NaN	NaN
25022019	NaN	NaN
NaN	0	0
25052019	NaN	NaN
25032019	NaN	NaN
25092019	NaN	NaN
25042019	NaN	NaN

O cpf 09639103101diz que há uma parcela atrasada na data 10/12/2019, mas os dias atrasados resgatados deste CPF vão até o dia 08/12/2019. Há dados faltantes (tabela 6).

Tabela 6: Dados do 09639103101 registra os pagamentos até o dia "08/12/2019" - coluna "dat_pgt" – ($\bf A$), mas há parcelas atrasadas no dia "10/12/2019" ($\bf B$). Faltam dados na tabela 5 $\bf A$.

Α	nulo	id_opr_cad_pos	id_mvt_cad_pos	id_pgt_cad_pos	dat_pgt
-183	3 days	2dd72848-0cc	75b762fc-465	831d635c-57d	2018-05-11
-59	days	2dd72848-0cc	64ef1873-ac6	31d96803-336	2018-10-12
7	7 days	2dd72848-0cc	dfe32d8e-83b	cb3e481e-5aa	2019-01-17
Ę	days	2dd72848-0cc	92060acc-512	b60487c0-bfb	2019-02-15
Ę	days	2dd72848-0cc	116c9441-70b	cbacf533-665	2019-04-15
8	3 days	2dd72848-0cc	ae8afb88-b27	e8e6a570-12b	2019-06-18
3	3 days	2dd72848-0cc	3289e976-fc0	4bb701ee-635	2019-09-13
148	3 days	2dd72848-0cc	66e165fb-aab	a8856bed-e84	2019-10-05
4	4 days	2dd72848-0cc	0918777a-01b	76a84975-a80	2019-10-14
238	3 days	2dd72848-0cc	b2bc90f5-f82	4409b9aa-1ea	2019-11-03
150	days	2dd72848-0cc	fad28e64-b02	9d6df0b0-c40	2019-12-07
120	days	2dd72848-0cc	18d4e571-e22	81ad4c7d-89a	2019-12-08

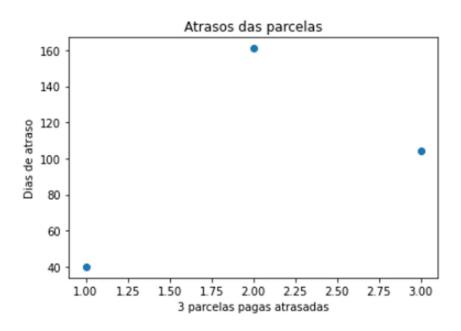
В	dat_vct	qtd_pcl_vnc	qtd_pcl_pgr
	10042019	NaN	NaN
	10012019	NaN	NaN
	10032019	NaN	NaN
	10092019	NaN	NaN
	10082019	NaN	NaN
	10122019	8	9

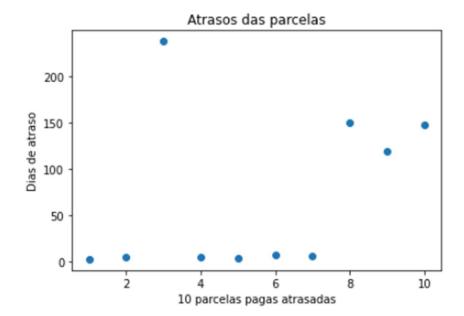
4.6. VISUALIZAÇÃO DO PERÍODO DE PAGAMENTO EM GRÁFICOS:

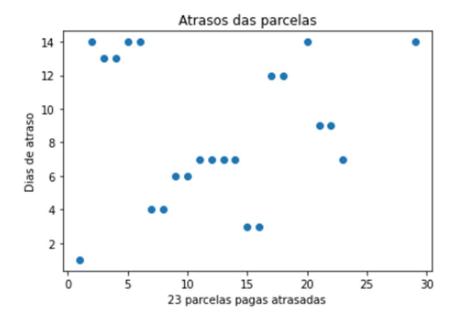
Construíram-se gráficos das tabelas do período de pagamento. Não há gráficos para o cpf 11435403525, por ausência de dados. Para cada CPF foi construído um gráfico mostrando os atrasos e outro mostrando os pagamentos feitos dentro do prazo.

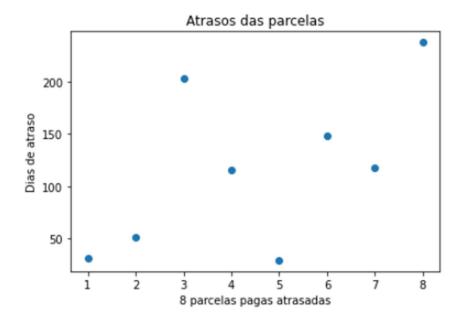
O eixo vertical mostra o total de dias. Se negativo ou zero, pagamentos feitos dentro do prazo. Se maior que zero, pagamentos feitos atrasados. O eixo horizontal mostra a quantidade de pagamentos, cada ponto plotado no gráfico refere-se a um pagamento. Agrupou-se os CPF's em relação aos atrasos: Sem atrasos: 64122018315, 53829829299, 28537130320, 38553034011; um atraso: 05227401381, 01367130760; dois atrasos: 18106900800; três atrasos: 12731112573, 24048813021; oito atrasos: 05309680888; dez atrasos: 09639103101; 23 atrasos: 06090237051. Lembrando que o 11435403525 não tem dados (p. 16-22).

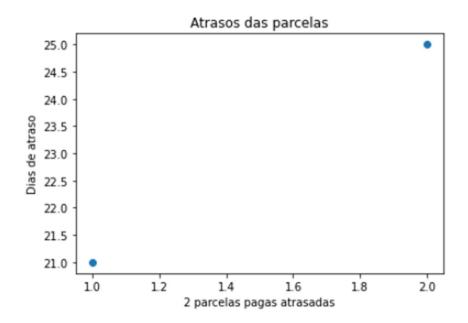




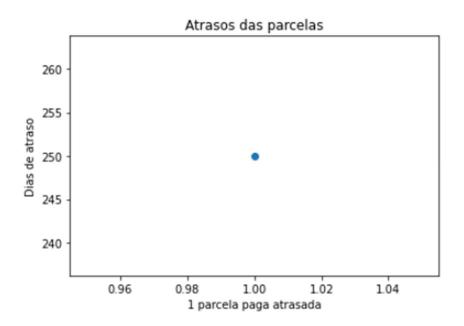


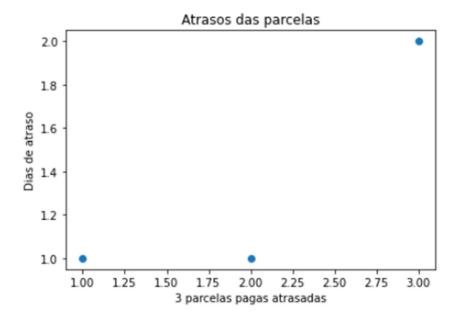














Sem Atrasos

28537130320

Sem Atrasos

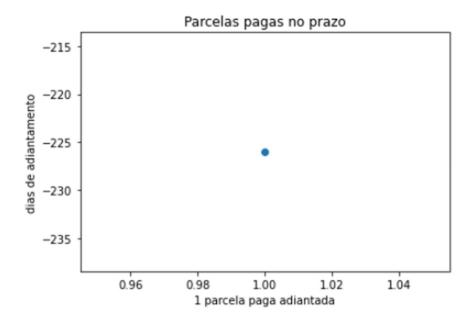
38553034011

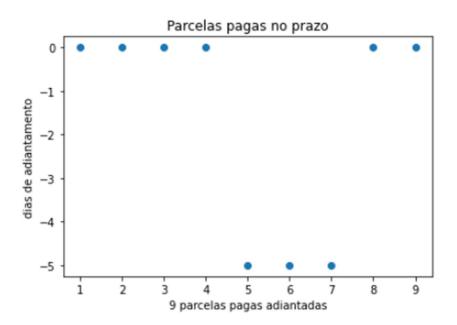
Sem Atrasos

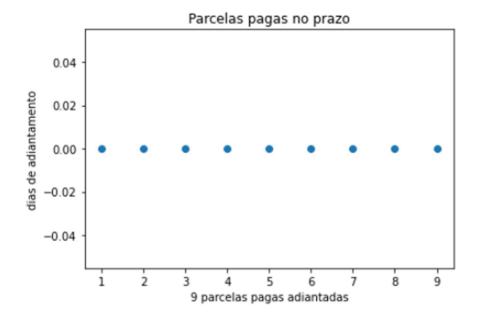
valores inesistentes

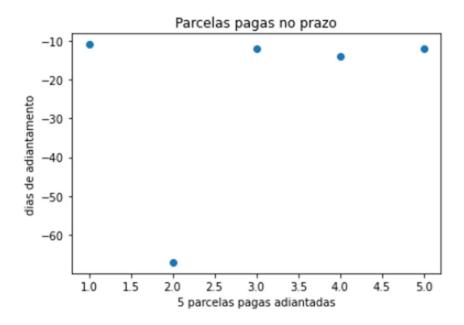
Os gráficos das páginas 22 até 29 mostram os pagamentos de cada CPF efetuados no prazo.

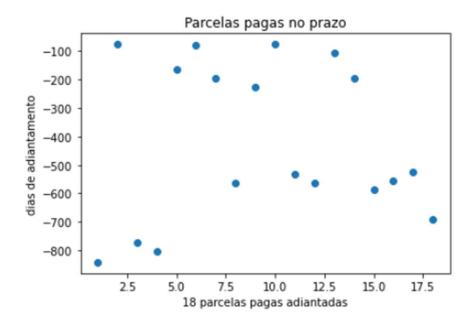


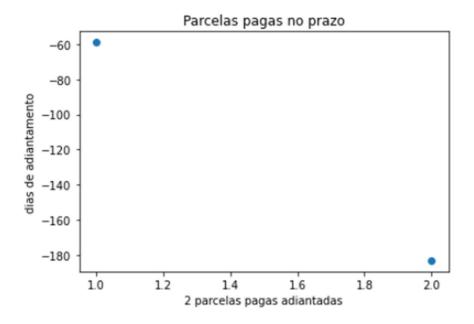




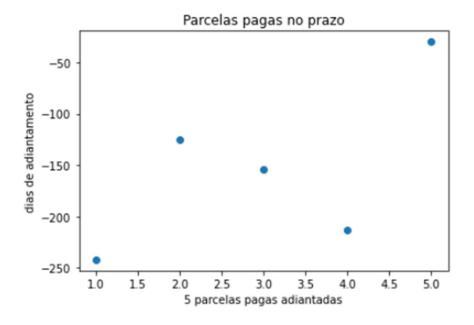


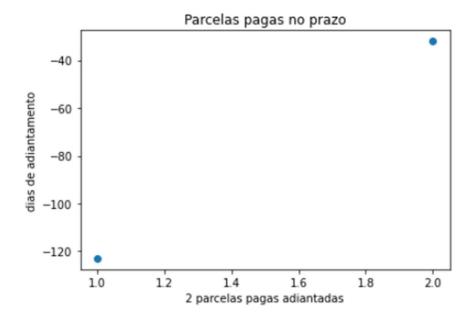


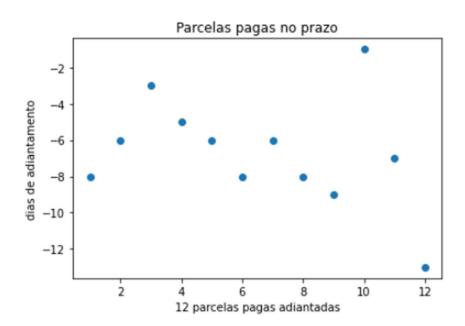


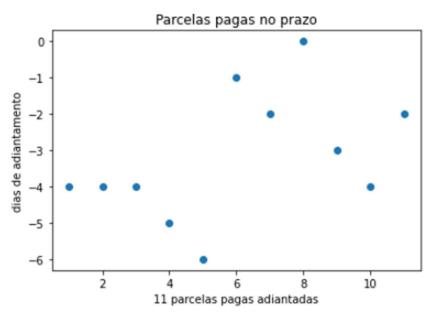












11435403525

valores inesistentes

4.7. GRÁFICOS DOS ESTADOS:

O cpf 11435403525 apareceu no gráfico de estados com a localização de "estado atual" no Ceará e "estado de origem do CPF" na Bahia ou Sergipe; e o cpf 01367130760 não se tem documentado (Fig. 5 e 6).

Figura 5: Exibição gráfica dos estados de residência atual de cada pessoa física em um total de 12 CPF's. O 01367130760 não tem informação.

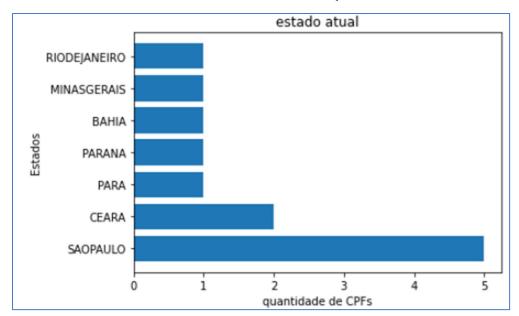


Figura 6: Exibição gráfica dos estados de origem de 12 dos CPF's. O 01367130760 não consta.



5. CONCLUSÃO:

Os únicos dados que se pode formular um algoritmo de validação foi o CPF e, a partir deles, rastrearam-se as operações de cada um. Houve muitos dados nulos que precisam ser corrigidos. A construção de gráficos do período de pagamento das parcelas deu um realismo às tabelas, reduzindo a característica caótica delas. As ferramentas utilizadas se mostraram eficiente para a conclusão deste trabalho.

Poucos CPF's foram considerados válidos, 13 CPF's; as outras 2989 linhas foram erros que precisam ser corrigidos. Todos os campos nulos são erros.

6. REFERÊNCIA BIBLIOGRÁFICA:

ALGORITMO PARA VALIDAR CPF. **Dicas de Programação**, 2015?. Disponível em: < https://dicasdeprogramacao.com.br/algoritmo-para-validar-cpf/#:~:text=Regra%20para%20validar%20CPF&text=O%20CPF%20C3%A9%20formado%20por,do%20sinal%20%22%2D%22).> Acesso em: 07/07/2020.